

# APUNTES INTELIGENCIA ARTIFICIAL

C. Axel

<sup>1</sup> *Tecnológico de Costa Rica, Escuela de Ingeniería en Computación  
Inteligencia Artificial - IC6200 - Grupo 2*

E-mail: [axelchaves.r@estudiantec.cr](mailto:axelchaves.r@estudiantec.cr)

## 1. INTRODUCCIÓN

A continuación se presenta una investigación con el propósito de mostrar una síntesis de los temas vistos en la clase de Inteligencia Artificial del martes 13 de febrero de 2024 a cargo del profesor Steven Pacheco Portuquez. Entre estos temas, se destaca la introducción al aprendizaje supervisado, álgebra lineal utilizada en aprendizaje supervisado, sets de datos, cálculo de distancias, entre otros. Además, se pretende reforzar el material de clase con investigaciones externas.

## 2. APRENDIZAJE SUPERVISADO

El aprendizaje supervisado se refiere a un conjunto de técnicas para deducir una función a partir de datos de entrenamiento y es una de las herramientas principales de la minería de datos y del aprendizaje automático [1]. Es decir, existe un conjunto de datos del cual se alimenta un algoritmo con el fin de determinar que la respuesta de este sea una específica basada en la entrada de datos [2].


Como características del aprendizaje supervisado, se puede destacar lo siguiente: contienen conjuntos de datos etiquetados, tienen pares de entrada y salida conocidos, los modelos se supervisan por medio de los datos y pueden componer distintos tipos de información (números, texto, audio, imágenes, entre otros). Los set de datos que se utilizan en el aprendizaje supervisado se refieren a colecciones de tamaño  $N$  que tienen la forma  $(X_i, Y_i)$  que donde  $X$  representa los features y  $Y$  las etiquetas.

### 2.1. Feature

Se refieren a una propiedad o atributo medible de una entidad. Además, en la mayoría de casos se representan de forma numérica para ser procesados por diversos algoritmos.

### 2.2. Feature Vector

Es un vector de  $D$  dimensiones donde cada dimensión representa a una características de un objeto. En la figura 1 se muestra un ejemplo de feature vector:



**Fig. 1:** Feature Vector con su espacio tridimensional y su gráfico en dos dimensiones.

### 2.3. Label

Se refiere a la información que se desea predecir o clasificar, la cual puede corresponder a números, clases y otras estructuras completas. En cuanto al dataset corresponde, las label siempre serán el elemento  $y$ .

### 2.4. Dataset

Se refiere a una colección de tamaño  $N$  y tienen la siguiente forma:

$$\{(x_i, y_i)\}_{i=1}^N \quad (1)$$

## 3. CONCEPTOS DE ÁLGEBRA LINEAL

### 3.1. Escalar

Se refiere a un valor numérico, lo cual es equivalente a un vector de una sola dimensión, por ejemplo:

$$escalar = 5 \quad (2)$$

### 3.2. Vector

Hace referencia a un objeto matemático que posee magnitud, dirección y sentido. En términos simples, es una lista de números [3].

$$\text{vector} = [1 \ 2 \ 3 \ 4] \quad (3)$$

### 3.3. Matriz

Se define como una lista compuesta de otras listas.

$$\begin{bmatrix} 1 & 2 & 3 \\ 4 & 5 & 6 \\ 7 & 8 & 9 \end{bmatrix}$$

### 3.4. Tensor

Se refiere a las matrices que superan las tres dimensiones.

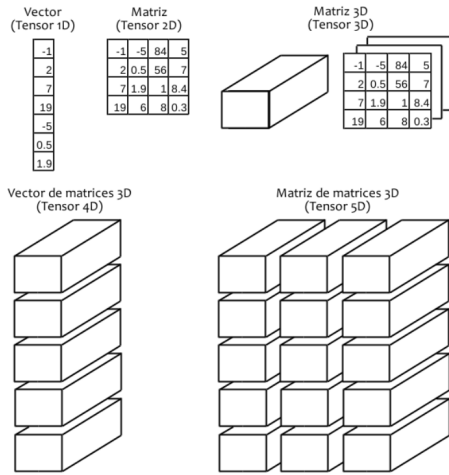


Fig. 2: Ejemplos de tensores en varias dimensiones.

### 3.5. Vector unidad

Se define como un vector que tiene una longitud o magnitud igual a 1. Además, este vector generalmente se utiliza para indicar la dirección de un vector sin considerar su longitud, lo cual simplifica los cálculos.




Fig. 3: Vector unidad junto a su expresión de magnitud.

### 3.6. Vector Co-direccional

Dos vectores se consideran co-direccionales si tienen la misma dirección, incluso si tienen diferente magnitud. Además, el ángulo de dos vectores co-direccionales es cero.

### 3.7. Vectores ortogonales

Dos vectores son ortogonales si su producto escalar es cero.




Fig. 4: Ejemplo de vectores ortogonales.

### 3.8. PRODUCTO PUNTO

También se le conoce como producto escalar o producto interno y es una operación entre dos vectores en el cual su resultado es un escalar.

$$u * v \quad (4)$$

## 4. Propiedades del producto punto

### 4.1. Conmutatividad

$$\vec{v} \cdot \vec{u} = \vec{u} \cdot \vec{v} \quad (5)$$

### 4.2. Asociatividad al multiplicar por un número real

$$k(\vec{v} \cdot \vec{u}) = (k\vec{v}) \cdot \vec{u} = \vec{v} \cdot (k\vec{u}) \quad (6)$$

### 4.3. Distributividad con la suma

$$\vec{v} \cdot (\vec{u} + \vec{w}) = \vec{v} \cdot \vec{u} + \vec{v} \cdot \vec{w} \quad (7)$$

### 4.4. Si es diferente de cero

$$\vec{v} \cdot \vec{v} > 0 \quad (8)$$

## 5. CÁLCULO DE DISTANCIAS ENTRE LOS PUNTOS DE UN VECTOR

Los vectores contienen una dirección y una magnitud asociados y pueden ser definidos en un espacio  $N$  dimensional. Asimismo, los vectores poseen un punto de partida y un punto de llegada.

### 5.1. Magnitud de Vector o Norma

La magnitud del vector es la distancia del punto de origen y el punto de destino.

### 5.2. Distancia Manhattan (L1)

Se utiliza para calcular la distancia entre dos puntos en un espacio  $n$ -dimensional.

$$\text{Manhattan}(A, B) = |x_1 - x_2| + |y_1 - y_2| \quad (9)$$

### 5.3. Distancia Euclidean(L2)

Es una forma de calcular la distancia entre puntos, la cual se deduce a partir del teorema de Pitágoras.

$$d_E(P_1, P_2) = \sqrt{(x_2 - x_1)^2 + (y_2 - y_1)^2} \quad (10)$$

## REFERENCIAS

- [1] E.C. León, "Introducción a las máquinas de vector soporte (SVM) en aprendizaje supervisado", Trabajo de Fin de Grado en Matemáticas, Universidad de Zaragoza, 2023.
- [2] E. Acevedo, A. Serna and E. Serna, "Principios y características de las redes neuronales artificiales," Desarrollo e innovación en ingeniería, vol. 173.
- [3] M. Hernández, "Álgebra lineal", 1975.